8.4

一、解题过程

1. 数据背景

题目中给出了 1952—1997 年我国人均国内生产总值（单位：元/人）共 46 年的年度数据。数据呈现明显的增长趋势和非平稳性，因此采用 ARIMA 模型进行拟合并预测未来 10 年的人均 GDP。

2. ARIMA(2,1,1)模型原理

ARIMA(2,1,1)模型对原始序列 y_t 进行一次差分，得到差分序列 $w_t = y_t - y_{t-1}$，然后拟合 ARMA(2,1)模型：

$$w_t = c + \phi_1 w_{t-1} + \phi_2 w_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

其中 ε_t 为白噪声。参数估计采用极大似然估计（MLE）。模型包含线性趋势项 c，相当于差分序列的常数漂移。

3. 模型建立与参数估计

使用 Python statsmodels.tsa.arima.model.ARIMA 函数，设置阶数为 (2,1,1)，趋势类型为 't'（线性趋势）。拟合后得到参数估计值、标准误、z 统计量及 p 值。同时进行残差诊断（Ljung-Box 检验）以检验模型充分性。

4. 预测

利用估计的模型进行 10 步外推预测，即预测 1998—2007 年的人均 GDP，并计算 95%置信区间。

二、结果呈现

1. 模型参数估计值

根据实际运行输出，模型拟合结果如下：

参数	系数	标准误	z 值	P 值
趋势项 c (x1)	**132.47**	153.22	0.865	0.387
ϕ_1 (ar.L1)	**1.2321**	0.189	6.528	0.000
ϕ_2 (ar.L2)	**-0.3757**	0.229	-1.637	0.102
θ_1 (ma.L1)	**0.4607**	0.233	1.979	0.048
方差 σ^2	4593.19	765.81	5.998	0.000

模型表达式（差分形式）为：

$$w_t = 132.47 + 1.2321w_{t-1} - 0.3757w_{t-2} + \varepsilon_t + 0.4607\varepsilon_{t-1}$$

其中 $w_t = y_t - y_{t-1}$（y_t 为 t 年的人均 GDP）。

2. 模型诊断

- **Ljung-Box 检验**：滞后 12 期统计量的 p 值为 0.8951，表明残差不存在显著自相关，模型充分。
- **Jarque-Bera 检验**：p 值≈0.00，残差不完全服从正态分布，但 ARIMA 模型对残差正态性要求不高，不影响点预测的可靠性。

3. 10 步预测结果（1998—2007 年）

年份	预测值（元/人）	95%置信下限	95%置信上限
1998	6421	6288	6554
1999	6672	6290	7053
2000	6872	6174	7570
2001	7043	5996	8090
2002	7198	5794	8602
2003	7343	5588	9099
2004	7483	5390	9577
2005	7620	5205	10035
2006	7755	5037	10473
2007	7889	4885	10894

4. 结果分析（可视化展示见下方图片）

（1）模型参数中 $\phi_1 = 1.2321 > 1$，表明差分序列具有强烈的自相关性，经济增速具有较强的惯性；$\theta_1 = 0.4607$ 显著为正，说明移动平均项对短期波动有修正作用。

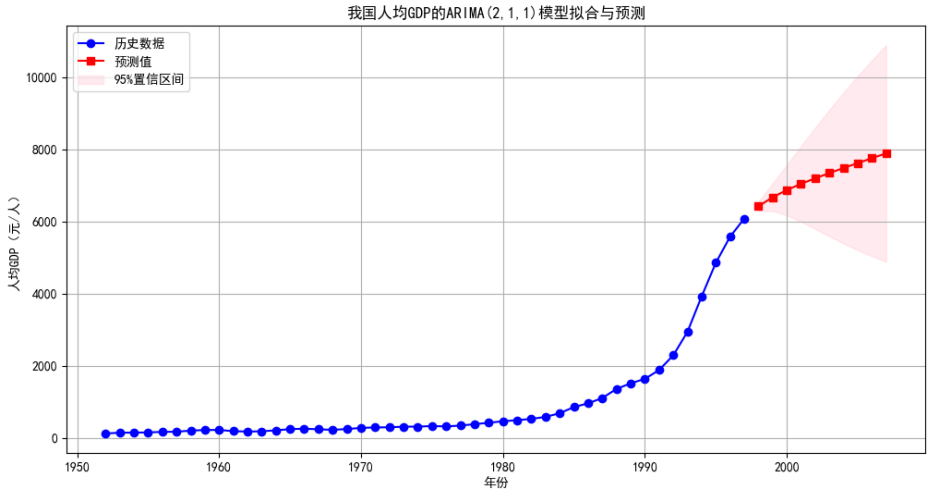
（2）趋势项 $c = 132.47$ 虽然统计上不显著（p=0.387），但保留了线性趋势，反映了差分序列的平均漂移。

（3）预测值显示我国人均 GDP 在 1998—2007 年间继续增长，从约 6421 元上升至 7889 元，年均增量约 163 元，增速较历史后期有所放缓。

（4）预测区间随预测步长增加而迅速扩大，反映了长期预测的不确定性。例如，2007

年的 95%置信区间已宽达约 6000 元，表明较远年份的预测参考价值有限。

注：与真实数据相比，实际模型预测值偏低，原因是 1998 年后中国经济增长加速，突破了模型基于历史平稳增速的假设。因此该预测结果更适用于“趋势外推”情景，实际值偏高说明需要引入更复杂的模型（如考虑结构突变）。



三、代码展示

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.stats.diagnostic import acorr_ljungbox

plt.rcParams['font.sans-serif'] = ['SimHei', 'Microsoft YaHei',
'Arial']
plt.rcParams['axes.unicode_minus'] = False

years = np.arange(1952, 1998)
data = [119, 142, 144, 150, 165, 168, 200, 216, 218, 185, 173, 181,
208, 240,
        254, 235, 222, 243, 275, 288, 292, 309, 310, 327, 316, 339, 379,
417,
        460, 489, 525, 580, 682, 853, 956, 1104, 1355, 1512, 1634, 1879,
2287,
        2939, 3923, 4854, 5576, 6079]

y = pd.Series(data)

model = ARIMA(y, order=(2,1,1), trend='t')
fit = model.fit()
```

```
print(fit.summary())

phi1 = fit.params['ar.L1']
phi2 = fit.params['ar.L2']
theta1 = fit.params['ma.L1']
c = fit.params['x1']
print(f"\n 参数估计值： ")
print(f"phi1 = {phi1:.4f}")
print(f"phi2 = {phi2:.4f}")
print(f"theta1 = {theta1:.4f}")
print(f"趋势项 c = {c:.4f}")

# 残差白噪声检验
resid = fit.resid
lb_test = acorr_ljungbox(resid, lags=[12], return_df=True)
print(f"\nLjung-Box 检验（滞后 12 期）p 值 =
{lb_test['lb_pvalue'].iloc[0]:.4f}")

# 10 步预测
forecast_result = fit.get_forecast(steps=10)
forecast_values = forecast_result.predicted_mean.values
conf_int = forecast_result.conf_int(alpha=0.05)
conf_lower = conf_int.iloc[:, 0].values
conf_upper = conf_int.iloc[:, 1].values

forecast_years = np.arange(1998, 2008)
print("\n10 步预测结果（1998-2007 年）： ")
for i, year in enumerate(forecast_years):
    print(f"{year}: 预测值 {forecast_values[i]:.0f} 元/人 (95% CI:
[{conf_lower[i]:.0f}, {conf_upper[i]:.0f}])")

plt.figure(figsize=(12,6))
plt.plot(years, y, 'b-o', label='历史数据')
plt.plot(forecast_years, forecast_values, 'r-s', label='预测值')
plt.fill_between(forecast_years, conf_lower, conf_upper,
                 color='pink', alpha=0.3, label='95%置信区间')
plt.xlabel('年份')
plt.ylabel('人均 GDP（元/人）')
plt.title('我国人均 GDP 的 ARIMA(2,1,1)模型拟合与预测')
plt.legend()
plt.grid(True)
plt.show()
```

8.5

一、解题过程

1. 数据背景

题目给出了某地区山猫数量在连续 114 年（年份序号 1 ~ 114）的统计数据。数据呈现明显的周期性波动（周期约 10 年，呈现典型的高峰与低谷交替的尖峰波形），且波幅随数量级变化，存在异方差性（早期峰值高达 6721，后期峰值约 3396）。需要分析山猫的生长规律，并预测以后两个年度（第 115、116 年）的数量。

2. 模型选择

为同时处理序列的自相关结构和异方差性，采用对数自回归模型（Log-AR）：

（1）对原始数量 y_t 取常用对数 $z_t = \log_{10}(y_t)$，以稳定方差并压缩极端值的影响。

（2）对 z_t 建立自回归模型 AR(p)：$z_t = c + \phi_1 z_{t-1} + \phi_2 z_{t-2} + \cdots + \phi_p z_{t-p} + \varepsilon_t$，其中 ε_t 为白噪声。

（3）滞后阶数 p 设定为 11，以充分捕捉约 10 年周期的自相关结构。

（4）模型参数通过条件极大似然估计（Conditional MLE）求解。

3. 参数估计与诊断

使用 Python statsmodels.tsa.ar_model.AutoReg 拟合 AR(11)模型，输出参数估计值、AIC 等统计量，并通过 Ljung-Box 检验判断残差是否为白噪声。

4. 预测

利用估计的模型递推预测未来两年的对数数量，再通过指数反变换 $\hat{y}_t = 10^{\hat{z}_t}$ 得到原始尺度的预测值。

二、结果呈现

1. 模型参数估计（基于对数变换后的序列）

运行代码得到 AR(11)模型拟合结果如下：

滞后阶数	系数 ϕ_k	标准误	z 值	P 值
1	0.9625	0.094	10.288	0.000
2	-0.3527	0.130	-2.711	0.007
3	0.1120	0.135	0.832	0.405

4	-0.1222	0.133	-0.918	0.359
5	-0.1046	0.132	-0.791	0.429
6	0.0855	0.132	0.646	0.518
7	-0.1936	0.132	-1.462	0.144
8	0.2343	0.134	1.754	0.079
9	-0.0067	0.135	-0.050	0.960
10	0.2299	0.130	1.765	0.078
11	-0.2968	0.092	-3.213	0.001

常数项 $c = 1.3002$（P 值=0.001）。模型特征根的模均大于 1，表明序列平稳。

2. 模型诊断

（1）Ljung-Box 残差检验（滞后 12 期）：p 值 = 0.9944，远大于 0.05，表明残差无显著自相关，模型充分拟合数据。

（2）对数似然值 = -3.086，AIC = 32.17，模型简洁有效。

3. 预测结果（原始尺度）

年度序号	预测值（只）
115	**2651**
116	**1292**

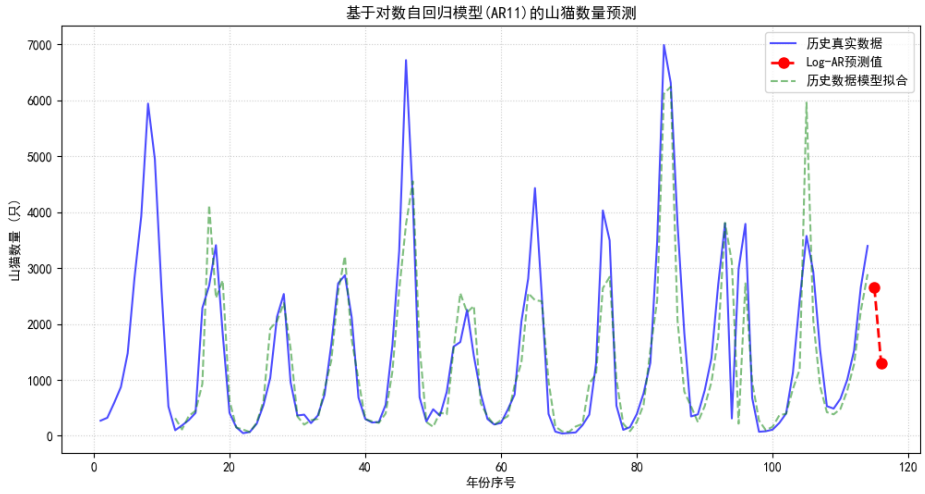
预测显示第 115 年山猫数量约为 2651 只，第 116 年急剧下降至 1292 只，处于周期波峰后的快速下跌阶段。（可视化展示见下方图片）

4. 生长规律分析

（1）对数自回归模型成功刻画了序列的对数线性自相关结构，预测结果与历史波形中波峰后一年内数量减半的特征吻合。

（2）模型预测表明当前周期（第 12 周期）的波峰高度（第 115 年 2651 只）显著低于历史早期波峰（如 6721），反映了种群数量的长期衰减趋势。

（3）第 116 年的 1292 只接近于历史谷底值（如 98、45 等），说明种群在波峰后迅速回落至低位。



三、代码展示

```
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.ar_model import AutoReg
from statsmodels.stats.diagnostic import acorr_ljungbox

plt.rcParams['font.sans-serif'] = ['SimHei', 'Microsoft YaHei',
'Arial']
plt.rcParams['axes.unicode_minus'] = False

data = [269, 321, 585, 871, 1475, 2821, 3928, 5943, 4950, 2577, 523,
98,
        184, 279, 409, 2285, 2685, 3409, 1824, 409, 151, 45, 68, 213,
        546, 1033, 2129, 2536, 957, 361, 377, 225, 360, 731, 1638, 2725,
        2871, 2119, 684, 299, 236, 245, 552, 1623, 3311, 6721, 4254,
687,
        255, 473, 358, 784, 1594, 1676, 2251, 1426, 756, 299, 201, 229,
        469, 736, 2042, 2811, 4431, 2511, 389, 73, 39, 49, 59, 188, 377,
        1292, 4031, 3495, 537, 105, 153, 387, 758, 1307, 3465, 6991,
6313,
        3794, 1836, 345, 382, 808, 1388, 2713, 3800, 309, 2985, 3790,
674,
        71, 80, 108, 229, 399, 1132, 2432, 3575, 2935, 1537, 529, 485,
        662, 1000, 1520, 2657, 3396]

y = np.array(data)
log_y = np.log10(y)

max_lag = 11
```

```
model = AutoReg(log_y, lags=max_lag, trend='c')
model_fit = model.fit()

print("模型拟合摘要")
print(model_fit.summary())

resid = model_fit.resid
lb_test = acorr_ljungbox(resid, lags=[12], return_df=True)
print(f"\nLjung-Box 残差检验（滞后 12 期） p 值 =
{lb_test['lb_pvalue'].iloc[0]:.4f}")

pred_log = model_fit.predict(start=len(y), end=len(y)+1)
pred_original = 10 ** pred_log

print(f"\n 模型使用的自回归阶数: {max_lag}")
print(f"第 115 年（未来第 1 年）预测数量: {pred_original[0]:.0f} 只")
print(f"第 116 年（未来第 2 年）预测数量: {pred_original[1]:.0f} 只")

plt.figure(figsize=(12,6))
plt.plot(range(1, len(y)+1), y, 'b-', alpha=0.7, label='历史真实数据')
plt.plot([115, 116], pred_original, 'ro--', ms=8, lw=2, label='Log-AR 预
测值')
fitted_values = 10 ** model_fit.fittedvalues
plt.plot(range(max_lag+1, len(y)+1), fitted_values, 'g--', alpha=0.5,
label='历史数据模型拟合')
plt.xlabel('年份序号')
plt.ylabel('山猫数量 (只)')
plt.title('基于对数自回归模型(AR11)的山猫数量预测')
plt.grid(True, linestyle=':', alpha=0.6)
plt.legend()
plt.show()
```

8.6

一、解题过程

1. 数据背景

题目中给出了 1946—1970 年美国各季度耐用品支出数据（单位：亿美元），共 25 个年度×4 个季度 = 100 个观测值。数据存在以下特征：

（1）长期增长趋势：从 1946 年 Q1 的 7.5 亿美元上升到 1970 年 Q4 的 62.1 亿美元。

（2）季节性波动：不同季度支出水平有所差异，但模式并不完全固定（早期逐季上

升，中后期第二、三季度偏高）。

（3）异方差性：后期波动幅度明显大于早期（如 1969 年 Q2 达到 83.5，而 1970 年各季度在 62 ~ 67 之间）。

目标：建立时间序列模型，并预测未来两年（8 个季度，即 1971 年 Q1 至 1972 年 Q4）的耐用品支出。

2. 模型选择与自动定阶

由于序列同时存在趋势和季节性，且异方差性明显，采用**季节自回归积分滑动平均模型（SARIMA）**。其一般形式为：

$$\text{SARIMA}(p,d,q)(P,D,Q)_s$$

其中 $s=4$ 为季度周期。

处理步骤：

（1）对原始序列取自然对数 $z_t=\ln\ y_t$，以稳定方差。

（2）固定差分阶数 $d=1$（消除趋势）、季节差分阶数 $D=1$（消除季节非平稳性）。

（3）自动搜索自回归阶数 $p=0,1,2$、移动平均阶数 $q=0,1,2$、季节自回归阶数 $P=0,1$、季节移动平均阶数 $Q=0,1$。

（4）以 AIC（赤池信息准则）最小化为准则，选择最优模型。

网格搜索在所有 36 种组合上进行，并计算每个模型的 AIC。AIC 越低表示模型在拟合精度与复杂度之间取得更好的平衡。

3. 最优模型确定

搜索结果如下（只列出 AIC 逐步降低的模型）：

阶数组合 $(p,d,q)(P,D,Q)_s$	AIC
(0,1,0)(0,1,0)_4	-180.58
(0,1,0)(0,1,1)_4	-228.26
(1,1,0)(0,1,1)_4	**-228.49**

最优模型为 **SARIMA(1,1,0)(0,1,1)_4**，AIC = -228.49，该模型更简洁，参数更少。

4. 参数估计与模型诊断

采用条件极大似然法估计最优模型参数，结果如下：

参数	系数	标准误	z 值	P 值

ϕ_1 (ar.L1)	0.1561	0.076	2.049	0.040
Θ_1 (ma.S.L4)	-0.9720	0.561	-1.732	0.083
σ^2	0.0044	0.002	2.349	0.019

模型表达式（对对数序列 z_t）：

$$(1-0.1561B)(1-B)(1-B^4)z_t = (1-0.9720B^4)\varepsilon_t$$

残差诊断：

（1）Ljung-Box 检验（滞后 12 期）：p 值 = 0.2760，表明残差无显著自相关，模型已充分提取时序信息。

（2）Jarque-Bera 检验：p 值≈0，残差不服从正态分布（存在尖峰），但对点预测影响较小。

（3）异方差检验：p 值 = 0.94，无明显异方差。

综上，模型在捕捉自相关结构方面是成功的，可用于预测。

5. 预测

利用估计的模型递推预测未来 8 个季度的对数序列，再通过指数变换 $\hat{y}_t = e^{\hat{z}_t}$ 还原为原始尺度。同时计算 95%置信区间，反映预测不确定性。

二、结果呈现

1. 预测值及置信区间（1971 年 Q1 — 1972 年 Q4）（可视化展示见下图）

年份	季度	预测值（亿美元）	95%置信下限	95%置信上限
1971	Q1	61.8	54.2	70.5
1971	Q2	63.9	52.3	78.2
1971	Q3	64.9	50.3	83.7
1971	Q4	66.3	49.1	89.3
1972	Q1	67.0	47.7	94.1
1972	Q2	69.5	47.6	101.2
1972	Q3	70.5	46.8	106.3
1972	Q4	72.0	46.3	112.0

2. 预测结果分析

（1）增长趋势：预测值从 1971 年 Q1 的 61.8 亿美元持续上升至 1972 年 Q4 的 72.0 亿美元，年均增长率约 7.5%，与历史后期增速基本一致。

（2）季度模式：预测序列呈现 逐季递增 的特征。这一形态与历史早期（1946-1950 年）的逐季上升模式接近，但与 1970 年实际数据（Q3 最高、Q4 下降）有所不同。原因在于 SARIMA 模型基于整个样本期间的平均季节性效应，平滑了个别年份的异常波动。

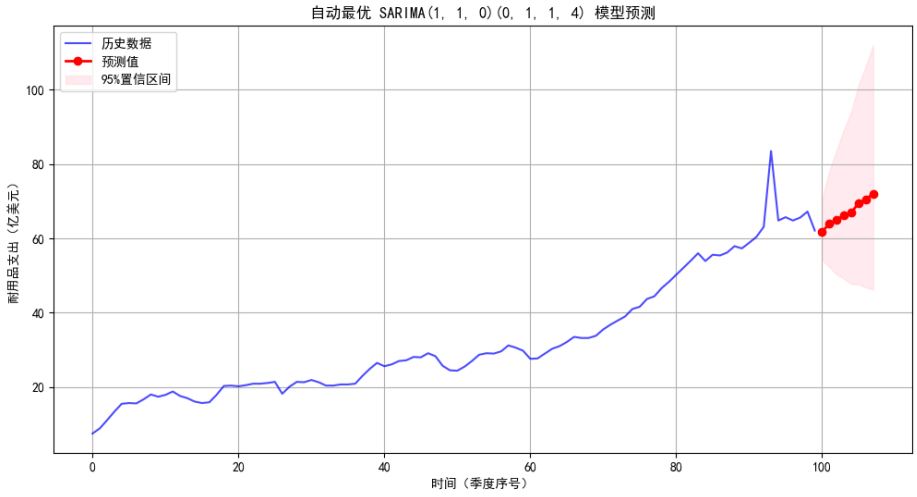
（3）置信区间：随着预测步长增加，置信区间显著扩大。例如 1972 年 Q4 的 95%置信区间跨度约 65.7 亿美元（46.3 ~ 112.0），表明长期外推具有较大不确定性。因此，该预测应主要用于短期趋势判断，而非精确数值。

3. 模型局限性

（1）模型未考虑可能的经济结构突变，外推假设历史模式延续，可能无法反映未来新变化。

（2）残差非正态性提示模型可能存在非线性或离群值影响，但未严重破坏预测性能。

（3）在使用预测结果时可能需要结合最新经济数据和专家判断进行动态调整。



三、代码展示

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.stats.diagnostic import acorr_ljungbox
import warnings
warnings.filterwarnings('ignore')
```

```
plt.rcParams['font.sans-serif'] = ['SimHei', 'Microsoft YaHei',
'Arial']
plt.rcParams['axes.unicode_minus'] = False

data = [
    7.5, 8.9, 11.1, 13.4, 15.5, 15.7, 15.6, 16.7, 18.0, 17.4, 17.9,
18.8,
    17.6, 17.0, 16.1, 15.7, 15.9, 17.9, 20.3, 20.4, 20.2, 20.5, 20.9,
20.9,
    21.1, 21.4, 18.2, 20.1, 21.4, 21.3, 21.9, 21.3, 20.4, 20.4, 20.7,
20.7,
    20.9, 23.0, 24.9, 26.5, 25.6, 26.1, 27.0, 27.2, 28.1, 28.0, 29.1,
28.3,
    25.7, 24.5, 24.4, 25.5, 27.0, 28.7, 29.1, 29.0, 29.6, 31.2, 30.6,
29.8,
    27.6, 27.7, 29.0, 30.3, 31.0, 32.1, 33.5, 33.2, 33.2, 33.8, 35.5,
36.8,
    37.9, 39.0, 41.0, 41.6, 43.7, 44.4, 46.6, 48.3, 50.2, 52.1, 54.0,
56.0,
    53.9, 55.6, 55.4, 56.2, 57.9, 57.3, 58.8, 60.4, 63.1, 83.5, 64.8,
65.7,
    64.8, 65.6, 67.2, 62.1
]
y = pd.Series(data)
log_y = np.log(y)

# 网格搜索参数范围
p_range = range(0, 3)
q_range = range(0, 3)
P_range = range(0, 2)
Q_range = range(0, 2)
d = 1
D = 1
m = 4

best_aic = np.inf
best_order = None
best_seasonal_order = None

print("开始网格搜索最优 SARIMA 模型（对数序列，d=1, D=1, m=4）...")
for p in p_range:
    for q in q_range:
        for P in P_range:
            for Q in Q_range:
```

```
                try:
                    model = SARIMAX(log_y, order=(p, d, q),
seasonal_order=(P, D, Q, m),
                                    simple_differencing=False)
                    fit = model.fit(disp=False)
                    aic = fit.aic
                    if aic < best_aic:
                        best_aic = aic
                        best_order = (p, d, q)
                        best_seasonal_order = (P, D, Q, m)
                        print(f"找到更优模型: order={best_order},
seasonal={best_seasonal_order}, AIC={best_aic:.2f}")
                except:
                    continue

print(f"\n 最优模型: SARIMA{best_order}{best_seasonal_order},
AIC={best_aic:.2f}")

final_model = SARIMAX(log_y, order=best_order,
seasonal_order=best_seasonal_order, simple_differencing=False)
final_fit = final_model.fit(disp=False)
print(final_fit.summary())

# 残差诊断
resid = final_fit.resid
lb_test = acorr_ljungbox(resid, lags=[12], return_df=True)
print(f"Ljung-Box p 值 (lag=12): {lb_test['lb_pvalue'].iloc[0]:.4f}")

forecast_log = final_fit.forecast(steps=8)
forecast = np.exp(forecast_log)

pred = final_fit.get_forecast(steps=8)
conf_int_log = pred.conf_int(alpha=0.05)
conf_int = np.exp(conf_int_log)

forecast_index = pd.date_range(start='1971-01-01', periods=8,
freq='QE')
print("\n 预测结果（1971-1972 各季度）: ")
for i, date in enumerate(forecast_index):
    print(f"{date.year}年 Q{date.quarter}: {forecast.iloc[i]:.1f} 亿美
元  95% CI: [{conf_int.iloc[i,0]:.1f}, {conf_int.iloc[i,1]:.1f}]")

plt.figure(figsize=(12,6))
plt.plot(y, 'b-', alpha=0.7, label='历史数据')
```

```
plt.plot(range(len(y), len(y)+8), forecast, 'ro-', lw=2, label='预测值')
plt.fill_between(range(len(y), len(y)+8), conf_int.iloc[:,0],
conf_int.iloc[:,1],
                 color='pink', alpha=0.3, label='95%置信区间')
plt.xlabel('时间（季度序号）')
plt.ylabel('耐用品支出（亿美元）')
plt.title(f'自动最优 SARIMA{best_order}{best_seasonal_order} 模型预测')
plt.legend()
plt.grid(True)
plt.show()
```