同济大学

TONGJI UNIVERSITY

本科毕业设计（论文）

课题名称	智能交通轨迹修复与时间预测
副 标 题	数学建模期中大作业报告
学　　院	计算机科学与技术学院
专　　业	数据科学与大数据技术（精英班）
学生姓名	费凡　张哲豪　王浩羽
指导教师	胡亮教授
日　　期	2026 年 5 月 17 日

智能交通轨迹修复与时间预测

装 订 线

摘 要

本文围绕智能交通场景中的两个轨迹建模任务展开研究：任务 A 要求在极稀疏采样条件下恢复出租车轨迹缺失坐标，任务 B 要求根据完整降采样轨迹和出发时间预测行程总耗时。针对任务 A，本文首先比较线性插值、Transformer 残差回归和路网 A* 约束等方案，发现纯坐标回归难以稳定判断长缺失区间中的真实道路选择，而静态路网最短路也难以刻画出租车实际行驶路线。最终采用历史轨迹模板检索方法，将训练集完整轨迹切分为不同 gap 长度的局部片段，通过 KDTree 检索起终点和上下文相似的历史模板，并将历史片段相对于线性插值的残差叠加到当前缺失区间。该方法无需训练神经网络，主要复用训练集中真实出现过的局部道路形状，在 1/8 全量验证集上达到 MAE 55.26 m、RMSE 83.20 m，在 1/16 全量验证集上达到 MAE 101.68 m、RMSE 150.35 m，显著优于线性插值和 Transformer 对比方法。

针对任务 B，本文通过数据探索发现轨迹点数与总行程时间具有强相关性，因此构造点数中位数 baseline，并使用 Residual Transformer 学习该 baseline 未解释的残差。模型融合点级轨迹特征、路径距离、绕行系数和出发时间等全局特征，在验证集上将 MAE 从点数中位数 baseline 的 21.186 s 降低到 15.982 s。实验结果表明，在强采样先验存在的条件下，稳定基线结合残差修正能够获得较好的精度和可部署性；其中任务 A 使用空间残差复用历史轨迹形状，任务 B 使用时间残差修正行程耗时估计。

关键词：轨迹修复，历史模板检索，残差学习，Transformer，到达时间预估

目 录

1 问题分析 …… 1
1.1 任务背景与整体理解 …… 1
1.2 数据探索 …… 1
1.3 关键挑战 …… 2
2 Task A 方法设计 …… 3
2.1 方法探索与最终选择 …… 3
2.2 对比方法：Transformer 残差回归实验 …… 3
2.3 最终方法：历史轨迹模板检索 …… 4
3 Task A 实验与分析 …… 6
3.1 实验设置与调参过程 …… 6
3.2 实验结果 …… 7
3.3 可视化展示 …… 8
3.4 路网信息的作用分析 …… 8
4 Task B 方法设计 …… 9
4.1 核心思路 …… 9
4.2 算法流程与模型结构 …… 9
5 Task B 实验与分析 …… 10
5.1 实验设置 …… 10
5.2 实验结果与消融分析 …… 10
5.3 可视化展示 …… 11
6 总结与分工 …… 13

装 订 线

1 问题分析

1.1 任务背景与整体理解

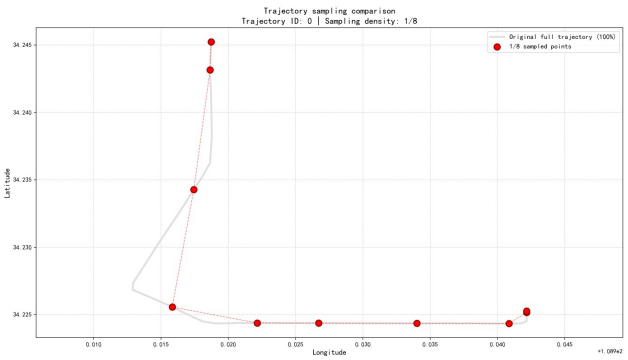
本题来源于智能交通系统中的轨迹数据修复与到达时间预估。原始数据为西安市出租车 GPS 轨迹，每条轨迹由不等长的经纬度和时间戳序列构成。两个子任务分别关注轨迹数据的两个典型应用：任务 A 在给定稀疏观测点的条件下恢复缺失坐标；任务 B 在给定完整降采样路径和出发时间的条件下预测总行程时间。

任务 A 本质上是带道路约束的时空插值问题。线性插值能够保证端点连续，但在弯道、路口、平行道路和绕行场景中容易产生明显偏差。任务 B 本质上是序列回归问题，输入路径已经包含完整坐标序列，建模重点在于结合轨迹长度、路径距离、路线形态、出发时间和局部停滞等因素估计行程耗时。两项任务共同说明，轨迹建模既需要利用几何信息，也需要利用数据中隐含的历史出行模式。

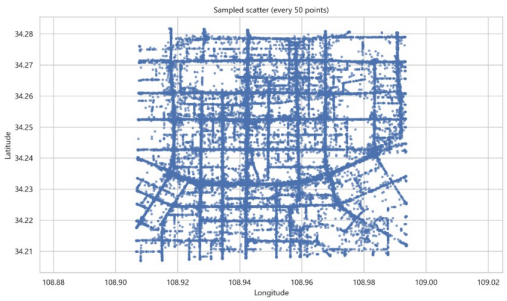
1.2 数据探索

任务 A 使用 `data_ds15/train.pkl` 中的 132657 条完整轨迹建立模型或模板库，验证集包含 16582 条完整轨迹。完整轨迹长度主要位于 50 到 240 点之间，训练集平均长度约 76.5，验证集平均长度约 76.8。预生成的 `val_input_8.pkl` 和 `val_input_16.pkl` 分别模拟 1/8 和 1/16 采样率，其中 1/8 输入平均每条轨迹约 10.9 个已知点，1/16 输入平均约 6.25 个已知点，说明任务 A 具有明显的极稀疏特征。初步数据探索还显示，原始轨迹速度主要落在城市道路合理区间，而极稀疏线性插值在转弯和绕行处容易产生过长直线段，从而诱发异常高速或穿越道路外区域的预测结果。

任务 B 使用同一份完整轨迹作为训练数据，真实行程时间由 $\text{timestamps}[-1] - \text{timestamps}[0]$ 得到。验证集轨迹点数范围约为 50 到 240，中位数约为 70；行程时间中位数约为 1074 s，平均行程时间约为 1186 s。由于数据来自约 15 s 间隔的降采样轨迹，轨迹点数与总行程时间天然具有强相关性，这一发现直接决定了任务 B 的基线模型设计。

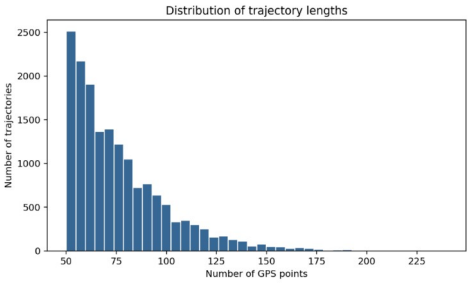


(a) 样本轨迹在经纬度坐标系上的可视化，原始轨迹与 1/8 采样点对比

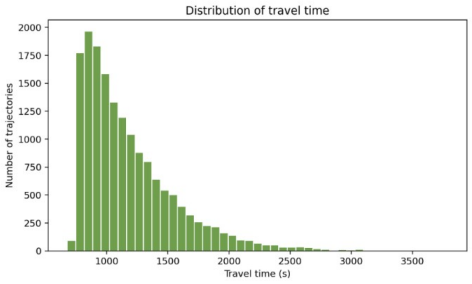


(b) 全数据集采样点空间分布散点图

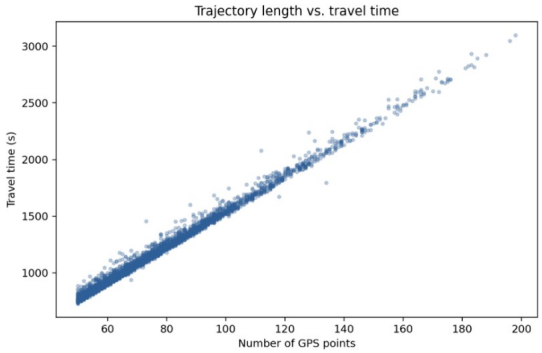
图 1.1 Task A 数据空间分布与稀疏采样示意



(a) 轨迹点数分布



(b) 行程时间分布



(c) 轨迹点数与行程时间散点图

图 1.2 Task B 数据分布与点数–耗时关系

1.3 关键挑战

任务 A 的挑战集中在极端稀疏性、道路约束和时序一致性。1/16 情况下平均每条轨迹只有约 6 个已知点，相邻已知点可能跨越多个路口；预测点不仅要接近真实坐标，还应贴近真实道路行驶轨迹，并保持合理速度、加速度和方向变化，否则容易出现穿越建筑、偏离路网或弯道形状失真。

任务 B 的挑战是输入信息受限、序列长度不定和时空因素复杂。验证输入只提供出发时间，不提供中间点和终点时间戳，不能直接计算真实速度或行程时长；轨迹点数分布在约 50 到 240 之间，需要通过 padding 和 mask 适配变长序列；同样点数的轨迹仍会因区域拥堵、绕行、停滞和出发时段不同而产生耗时差异。

2 Task A 方法设计

2.1 方法探索与最终选择

本文依次尝试了三类方案。第一类是 Transformer 残差回归：以线性插值结果、缺失掩码、时间差和最近道路偏移为输入，预测相对线性插值的二维坐标残差。该方法表达能力较强，但在 1/8 和 1/16 这种极稀疏条件下，模型需要从少量端点直接判断车辆实际走哪条路，训练目标受路口选择和历史路线模式影响较大，因此效果不稳定。

第二类是路网 A* 约束方法，其基本流程为已知 GPS 点匹配候选道路、搜索最短路径，并按时间比例沿路径补点。该方法使用了题目提供的 OSM 路网信息，但原型测试表明最近道路和最短路径难以直接代表出租车真实行驶路线，尤其在平行道路、路口、掉头和复杂道路结构中容易选错路径；同时全量验证需要大量最短路搜索，运行开销较高。

第三类是历史轨迹模板检索，也是最终采用的主方法。出租车数据具有重复路线和局部道路模式，训练集中存在大量真实发生过的完整 15 s 轨迹片段。该方法将训练集切分为局部模板，在预测时检索起终点和上下文相似的历史片段，并利用这些片段相对于线性插值的残差形状恢复缺失轨迹。

表 2.1 任务 A 三类方法的设计取舍

方法	主要信息来源	主要问题与结论
Transformer 残差回归	稀疏坐标、时间差、mask、最近道路偏移	能端到端学习，但长 gap 下端点信息不足，容易回归到平均路线形状，作为对比方法保留。
路网 A* 约束	OSM 路网、候选道路、最短路	使用了路网，但最短路不等于真实出租车路线;全量最短路搜索耗时高,不作为主线。
历史模板检索	完整训练轨迹中的真实局部片段	利用历史轨迹形状补偿线性插值误差；验证集效果最好，作为最终方案。

2.2 对比方法：Transformer 残差回归实验

Transformer 对比方法将轨迹修复建模为序列生成任务。预处理阶段首先将经纬度转换为局部米制坐标，再对缺失点进行线性插值得到初始骨架；随后计算相邻时间差、缺失掩码以及最近路网点相对插值点的偏移量。每个点的输入特征包括插值坐标、mask、时间差和路网偏移。

模型采用纯 Encoder 结构：输入特征经线性层映射到 $d_{\text{model}} = 256$，加入位置编码后送入 6 层、8 头注意力的 Transformer Encoder，最后通过线性层输出二维归一化坐标。训练损失同时包含缺失点修复损失和已知点重构损失：

$$L = L_{\text{repair}} + 0.1 L_{\text{reconstruct}}.$$

推理时只替换缺失点坐标，并保持已知点原始坐标不变。该方案作为深度学习对照组保留，用于比较端到端坐标回归与历史模板检索的效果差异。

2.3 最终方法：历史轨迹模板检索

历史模板检索方法以线性插值为基础，并利用历史轨迹残差补充真实道路形状。设一个缺失区间左端已知点索引为 l，右端已知点索引为 r，则

$$d = r - l$$

称为该区间的 gap 长度。若 $d = 8$，说明当前缺失区间由 1/8 采样产生，两个已知点之间有 7 个待恢复点；若 $d = 16$，则对应更长的 1/16 缺失区间。gap 用于描述缺失区间长度，并据此划分不同长度的模板库。

对训练集中的完整轨迹，本文按照不同 gap 长度枚举窗口：

$$[p_i, p_{i+1}, \ldots, p_{i+d}].$$

窗口起点和终点构成检索特征

$$\text{feature} = [x_i, y_i, x_{i+d}, y_{i+d}],$$

中间真实点相对于起终点线性插值的差值定义为历史残差：

$$\text{residual} = \text{middle_points} - \text{linear_interpolation}(p_i, p_{i+d}).$$

每种 gap 长度单独建立一个 KDTree，例如 KDTree_8 主要服务 1/8 输入，KDTree_{16} 主要服务 1/16 输入。

推理时，首先对当前缺失区间做线性插值，得到基础骨架；然后在对应 gap 的 KDTree 中检索 top-k 个起终点相似的历史片段；再利用前后上下文点进行候选重排，降低平行道路和路口分叉导致的错误模板概率。最终预测为

$$\text{pred_xy} = \text{linear_xy} + \text{weighted_average}(\text{history_residual}).$$

当前最终参数为：$k = 24$，bandwidth = 80，max_endpoint_error = 160，context_weight = 0.15，max_windows_per_gap = 3000000。其中 max_windows_per_gap 是内存控制参数，表示每种 gap 长度最多保留 300 万个历史窗口。

该方法的主要计算为历史窗口枚举、KDTree 查询和残差加权平均。模板库建立后可以复用，后续推理阶段只需对待修复轨迹逐段查询相同 gap 长度的历史片段，因此具有较好的可重复性和运行效率。

表 2.2 历史模板检索的推理流程

步骤	作用
局部投影	将经纬度转换为米制平面坐标，使端点距离、残差和 KDTree 检索具有统一量纲。
按 gap 建库	每种 gap 长度单独保存历史窗口，保证候选片段与当前缺失区间长度一致。
起终点检索	使用 $[x_l, y_l, x_r, y_r]$ 在 KDTree 中查找局部位置相似的历史片段。
上下文重排	结合当前 gap 前后的已知点，降低平行道路或路口分叉处选错模板的概率。
残差加权平均	对多个候选模板的残差进行加权平均，避免完全复制单条历史轨迹造成偶然错误。
坐标回填	将预测坐标反投影回经纬度，并保证原始已知点坐标完全不变。

表 2.3 历史模板检索关键参数含义

参数	含义与影响
$k = 24$	每个 gap 取 24 个候选模板。过小容易受单个错误模板影响，过大则会平均掉真实道路弯曲形状。
bandwidth = 80	端点距离加权的核宽度，控制相似模板权重衰减速度。
max_endpoint_error = 160	候选模板起终点允许误差上限，用于过滤明显不匹配的历史片段。
context_weight = 0.15	前后上下文点在候选重排中的权重，用于增强方向和局部运动趋势约束。
max_windows_per_gap = 3000000	每种 gap 最多保留 300 万个历史窗口，用于控制内存和缓存大小。

3 Task A 实验与分析

3.1 实验设置与调参过程

最终历史模板检索使用完整训练集 132657 条轨迹构建模板库，并在 16582 条验证轨迹上评估。评价指标仅在缺失点上计算 Haversine 距离，报告 MAE 和 RMSE：

$$\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N} d_i, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} d_i^2}.$$

其中 d_i 表示第 i 个待恢复点的预测坐标与真实坐标之间的 Haversine 距离。训练阶段主要包括历史窗口枚举、残差保存和 KDTree 构建。

参数调试采用由小规模验证到全量验证的流程。首先使用前 20 条或前 100 条验证轨迹检查数据读取、输出格式、已知点保持和异常坐标情况；随后从仅使用 gap 起终点的模板检索开始，逐步加入上下文重排，并调整 k、bandwidth、最大端点误差和上下文权重。端点检索在 1/8 前 100 条上约为 MAE 68.87 m、RMSE 102.04 m；加入上下文重排后提升到 MAE 66.60 m、RMSE 99.22 m；进一步调参后前 100 条最好约为 MAE 66.19 m、RMSE 98.02 m。最终参数在全量验证上表现更稳定。

表 3.1 任务 A 调参过程中的主要观察

实验阶段	观察结论
小规模验证	检查数据读取、输出格式、已知点保持和 NaN 坐标，避免直接在全量验证集上长时间试错。
端点检索	只看 gap 起终点已经明显优于线性插值，但在平行道路和路口附近容易选错模板。
上下文重排	利用前后已知点补充方向信息，前 100 条的 MAE 和 RMSE 均有下降。
候选数量调整	k 太小不稳定，k 太大又削弱路线形状；1/8 上 $k = 24$ 较稳。
扩大模板库	训练集前 60000 条到完整 132657 条，1/8 全量 MAE 从 55.70 m 降至 55.26 m，收益存在递减。

表 3.2 任务 A 模板构建与推理耗时

设置	训练轨迹数	全量验证耗时	峰值内存
1/8 建库 + 推理	132657	约 4.1 min	约 7.1 GB
1/16 建库 + 推理	132657	约 9.3 min	约 14.7 GB
1/16 模板复用推理	132657	约 57 s	约 7.6 GB

从运行时间看，主要开销集中在首次构建模板库。模板库建立后，推理阶段只需遍历缺失 gap 并查询对应 KDTree，计算量明显降低。这一特点使该方法在保持精度优势的同时，也具备较好的复现性和部署效率。

表 3.3 任务 A 1/8 采样率验证性能

方法	验证范围	MAE/m	RMSE/m
线性插值	全量 16582 条	95.20	128.26
路网 A* 原型	前 100 条	94.12	130.01
基础 Transformer	全量验证	79.16	100.94
路网 Transformer	全量验证	80.29	106.25
历史模板检索	全量 16582 条	55.26	83.20

表 3.4 任务 A 1/16 采样率验证性能

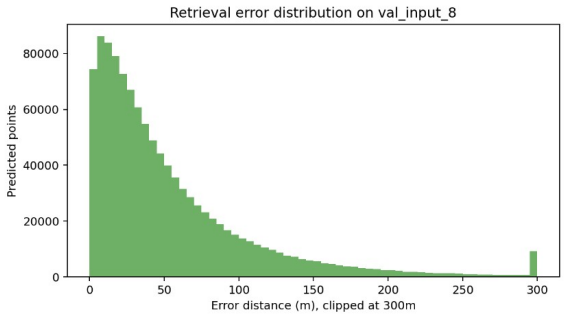
方法	MAE/m	RMSE/m
线性插值	174.12	230.42
基础 Transformer	119.82	152.27
路网 Transformer	124.70	165.65
历史模板检索	101.68	150.35

3.2 实验结果

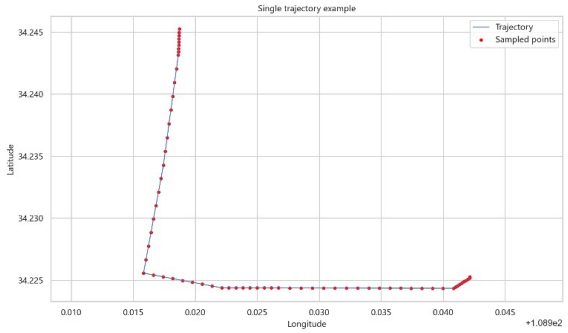
结果显示，历史模板检索在 1/8 全量验证集上将 MAE 从线性插值的 95.20 m 降至 55.26 m，RMSE 从 128.26 m 降至 83.20 m；在更困难的 1/16 场景下，MAE 从 174.12 m 降至 101.68 m，相对线性插值下降约 41.6%。这说明在极稀疏轨迹恢复中，复用历史轨迹中的真实局部形状，比直接回归坐标或单纯依赖静态路网更有效。

装 订 线

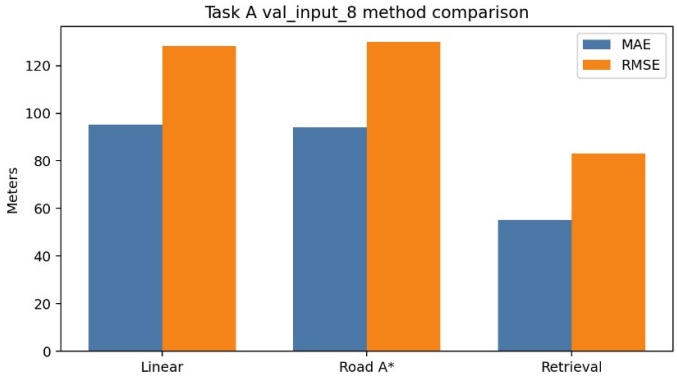
3.3 可视化展示



(a) 历史模板检索全量验证误差分布



(b) 单条轨迹采样示意图



(c) 线性插值、路网原型、历史模板检索的 MAE/RMSE 对比

图 3.1 Task A 可视化结果

3.4 路网信息的作用分析

路网信息能够提供道路连通性和空间约束，但直接将轨迹吸附到最近道路并使用 A* 最短路补全轨迹，在本题验证集上提升有限。主要原因包括：最近道路容易在平行道路场景下发生误匹配；最短路与出租车实际路线存在差异，实际行驶会受到红绿灯、拥堵、绕行和掉头等因素影响；长 gap 场景下候选道路组合较多，路径搜索的计算开销也明显增加。历史模板检索虽然没有显式使用路网图结构，但训练轨迹本身来自真实道路行驶过程，因此能够间接吸收道路形状和出行习惯信息。

从实验结果看，路网更适合作为候选过滤或合理性检查的辅助信息。后续可以在历史模板候选中加入道路可达性、道路拓扑一致性等约束，过滤明显偏离可行道路的片段；也可以在长 gap 场景下利用道路连通性削弱不合理模板的权重。考虑到地图匹配与路径搜索会增加实现复杂度和运行时间，本文最终采用历史轨迹模板检索作为主方法。

4 Task B 方法设计

4.1 核心思路

任务 B 的核心发现是轨迹点数与行程耗时高度相关。由于轨迹由约 15 s 间隔降采样得到，简单的 $15(n-1)$ 已经能够给出较强估计；进一步使用训练集中相同点数轨迹的行程时间中位数，可以校准实际采样间隔和尾部时间差异。因此本文采用基线残差预测框架：

$$\text{baseline}(n) = \text{median}\{t_i \mid \text{len}(\text{coords}_i) = n\},$$

$$\text{pred} = \text{baseline}(n) + f_\theta(\text{coords}, \text{departure_time}, \text{global_features}).$$

其中 f_θ 表示 Residual Transformer 输出的时间残差，用于刻画点数中位数基线尚未解释的路线形态、停滞和时段差异。

任务 B 的 residual 与任务 A 的 gap 含义不同。前者表示时间预测中的残差项，后者表示相邻已知点之间的索引间隔。两项任务在方法设计上均先构造稳定的基础估计，再利用数据驱动的残差信息补充细节：任务 A 以线性插值作为空间骨架，任务 B 以点数中位数作为时间基线。

4.2 算法流程与模型结构

点级特征为 7 维，包括经纬度、相邻坐标差分、步距、累计距离比例和序列位置比例。全局特征为 14 维，包括轨迹点数、总路径距离、起终点直线距离、绕行系数、起终点位置、出发小时和星期周期编码、高峰期标记及停滞比例等。模型主体为 Transformer Encoder：点级特征先经线性层映射到 d_{model}，加入可学习位置编码后输入 Encoder；Encoder 输出通过 masked mean pooling 得到整条轨迹表征，再与全局特征 MLP 表征拼接，最后通过回归头输出残差。

本次最终配置为：learning rate = 10^{-3}，loss 为 SmoothL1Loss，训练上限 30 epoch，min_epochs = 20，patience = 10，batch size = 384，$d_{\text{model}} = 64$，层数为 2，注意力头数为 4。损失函数为

$$L = \text{SmoothL1}(r_{\text{pred}},\ y - \text{baseline}(n)).$$

SmoothL1Loss 在小误差处具有平滑梯度，在大误差处比 MSE 更不容易被异常样本主导，适合出租车轨迹中存在停滞和长耗时样本的情况。

预测阶段对每条输入轨迹计算点数中位数基线，再由 Transformer 输出残差项，最终得到

$$\text{final_pred} = \text{baseline} + \text{residual_pred}.$$

后处理仅进行基本合理性约束，将预测耗时限制为正数并取整为秒。

5 Task B 实验与分析

5.1 实验设置

实验使用 `student_release/data_ds15/train.pkl` 作为训练集，使用 `student_release/task_B_tte/val_input.pkl` 和 `val_gt.pkl` 作为验证集，评价指标为 MAE、RMSE 和 MAPE。对任务 B，d_i 表示第 i 条轨迹预测行程时间与真实行程时间的绝对误差，MAE 和 RMSE 的计算方式与任务 A 一致；其中

$$\mathrm{MAPE} = \frac{1}{N}\sum_{i=1}^{N}\frac{|y_i - \hat{y}_i|}{y_i} \times 100\%,$$

用于衡量预测误差相对于真实行程时间的比例。训练过程中先进行 5 个 epoch 的预实验，确认模型可以稳定超过点数中位数基线；随后使用 20 epoch 和 early stopping，发现验证 MAE 已稳定在 16 s 左右；最终将训练上限设为 30 epoch，并加入 min_epochs = 20、patience = 10。最优点出现在第 11 轮附近，验证 MAE 为 15.982 s，后续训练仅小幅波动。

5.2 实验结果与消融分析

表 5.1 任务 B 验证集结果

方法	MAE/s	RMSE/s	MAPE
全局平均耗时	297.849	396.445	25.149%
$15 \times (n-1)$	48.938	60.828	4.041%
点数中位数基线	21.186	33.300	1.823%
Residual Transformer	15.982	25.283	1.371%

实验结果表明，轨迹点数本身提供了很强的时间先验。固定 15 s 间隔已经远优于全局平均耗时，点数中位数基线进一步将 MAE 降至 21.186 s。在此基础上，Residual Transformer 将 MAE 降至 15.982 s，相比点数中位数基线下降约 24.6%。这说明路径形态、空间区域、停滞比例和出发时间仍能解释一部分同点数样本之间的耗时差异。

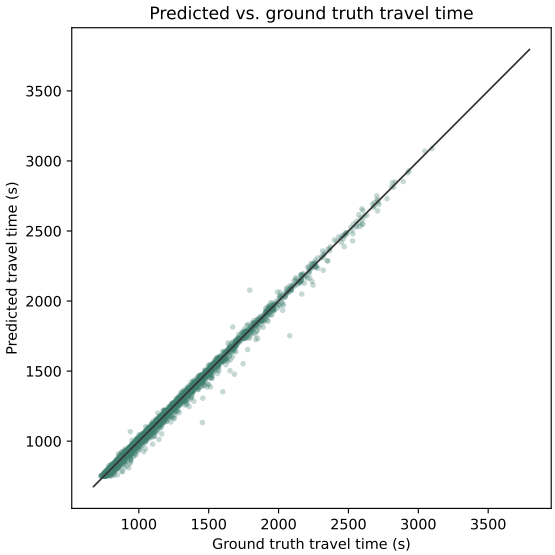
表 5.2 任务 B 轻量消融实验

实验设置	MAE/s	RMSE/s	MAPE	说明
$15 \times (n-1)$	48.938	60.828	4.041%	采样间隔先验
点数中位数	21.186	33.300	1.823%	使用训练集点数统计
点数 + 小时分组	21.555	33.775	1.843%	简单分组未提升
点数 + 高峰标记	21.222	33.302	1.825%	高峰标记提升有限
Residual Transformer	15.982	25.283	1.371%	学习基线残差

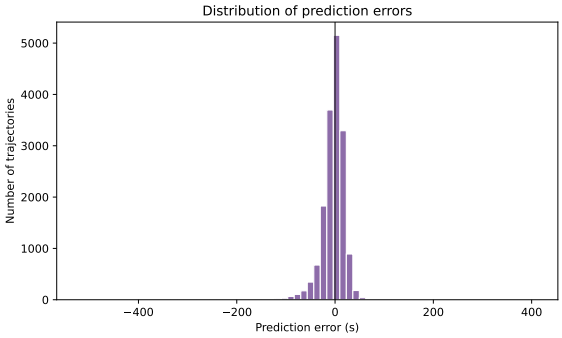
消融结果显示，简单地在基线中加入小时或高峰期分组没有带来提升，可能原因是分组后每组样本数量减少，中位数估计稳定性下降。Transformer 使用连续时间特征和序列特征刻画路径信息，

比直接按时段离散分组更稳定。

5.3 可视化展示

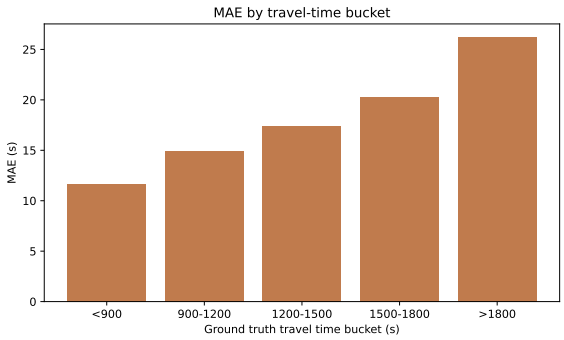


(a) 预测值与真实值

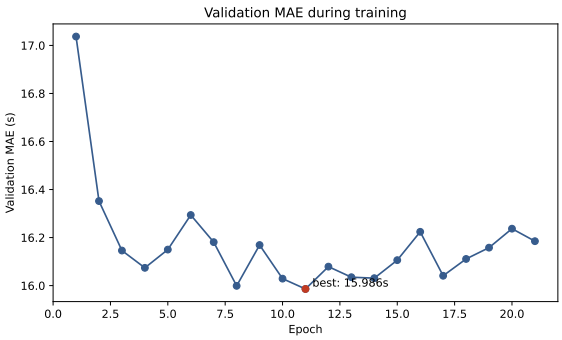


(b) 预测误差分布

图 5.1 任务 B 预测效果可视化



(a) 不同耗时区间 MAE



(b) 训练过程验证 MAE

图 5.2 任务 B 误差结构与训练曲线

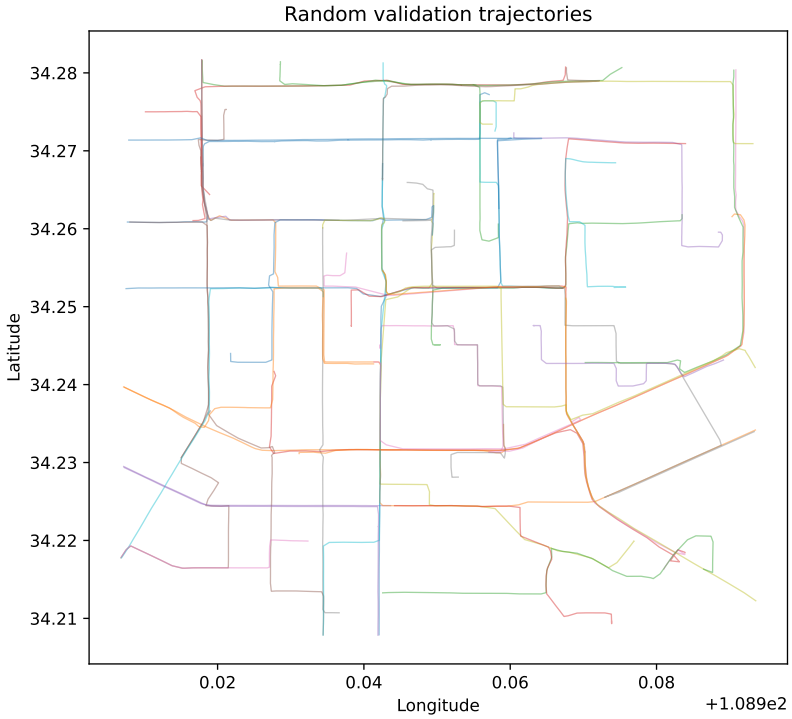


图 5.3 随机轨迹空间分布

从预测值与真实值散点图可以看到，多数样本分布在对角线附近，说明模型整体没有明显系统性偏高或偏低。误差分布以 0 为中心，长尾主要来自路线更长、停滞更明显或交通状态更复杂的样本。不同耗时区间的 MAE 进一步说明，短行程样本更容易预测，长耗时样本由于路径形态和交通条件变化更大，误差也更高。随机轨迹空间分布图展示了验证集轨迹的主要覆盖区域，为时间预测误差分析提供了空间背景。

装 订 线

6 总结与分工

本文针对两个任务分别采用了适合其数据结构的建模策略。任务 A 中，极稀疏采样导致纯坐标回归和静态路网最短路难以稳定恢复真实道路形状，最终采用历史轨迹模板检索，通过训练集中的真实局部片段补偿线性插值残差，在 1/8 全量验证集上达到 55.26 m MAE。任务 B 中，轨迹点数提供了有效的时间先验，Residual Transformer 在点数中位数基线上学习残差，将验证 MAE 降至 15.982 s。整体来看，两项任务均采用先建立稳定基础估计、再利用数据残差补充细节的建模思路。

分工方面，费凡负责任务 A Transformer 方法实现与实验；王浩羽负责任务 A 路网 Transformer 方法与路网特征探索；张哲豪负责任务 B 建模、任务 A 历史轨迹模板检索方法与课堂汇报。

装 订 线